

APPRENTISSAGE CONTINU PAR FEEDBACK HUMAIN POUR LA SEGMENTATION DES IRM DES MUSCLES DE LA JAMBE

Gossard Evan - Lafontaine Louis - Ranga Navin

PTI TDSI 20/12/2024

Dpt Génie Electrique, INSA Lyon

RÉSUMÉ

Ce projet propose une approche automatisée pour la segmentation d'IRM musculaires des jambes, basée sur l'apprentissage profond et continu à l'aide du feedback expert. Notre solution intègre un prétraitement des données IRM, une architecture U-Net pour la segmentation et un système d'apprentissage continu permettant d'améliorer la précision des segmentations.

Mots clés — segmentation IRM, deep learning, apprentissage continu, muscles, imagerie médicale.

1. INTRODUCTION

La segmentation des IRM musculaires représente un défi dans le domaine médical. Actuellement, le processus de segmentation des muscles sur les images IRM est réalisé manuellement par du personnel médical, une tâche chronophage et fastidieuse. Ce projet vise à développer une solution de segmentation des IRM de muscles de jambe, basée sur l'apprentissage continu, une approche d'entraînement où les modèles s'améliorent de manière incrémentale en intégrant de nouvelles données ou en corrigeant leurs erreurs grâce à un feedback humain.

Ce rapport s'articule autour de plusieurs axes :

- méthodes de prétraitement des données
- description de l'architecture U-Net
- implémentations de plusieurs approches d'apprentissage continu

2. METHODES

2.1. Prétraitement des données

Les données utilisées, fournies par Creatis, sont issues de séquences IRM de jambes de 5 patients. Le prétraitement comprend une normalisation des intensités dans $[0,1]$ pour faciliter l'apprentissage et une standardisation des dimensions par rééchantillonnage (soit par recadrage, soit par du padding) afin de détecter les structures d'intérêt et aligner les images et les labels.

Face à la taille limitée de la base de données, une stratégie d'augmentation est réalisée en appliquant des transformations, incluant des **zooms** (échelles variant de 0,95 à 1,05) et des **rotations** de $\pm 4^\circ$, accompagnées de légers **déplacements** ($\pm 5\%$) et **cisaillements** ($\pm 5^\circ$). Des ajustements d'intensité tels que des variations de **luminosité**, de **contraste** ($\pm 10\%$) et des modifications **gamma** ($\pm 10\%$ autour de la valeur nominale) sont également effectués sans altérer l'intégrité anatomique.




Figure 1 : Exemple de coupe 2D après traitement

La base de données (composée de **816** coupes) est divisée suivant la répartition suivante pour l'entraînement de la base de données dans la suite : **70%** pour l'entraînement, **15 %** pour la validation et **15 %** pour les tests.

2.2. Architecture du réseau

Pour la segmentation des coupes, il faut noter que chaque pixel des images labellisées appartient à une des 21 régions identifiées correspondant à un muscle spécifique de la jambe. Notre objectif étant de segmenter chaque muscle, nous avons sélectionné une architecture de type U-Net, en raison de sa capacité à capturer des détails locaux.

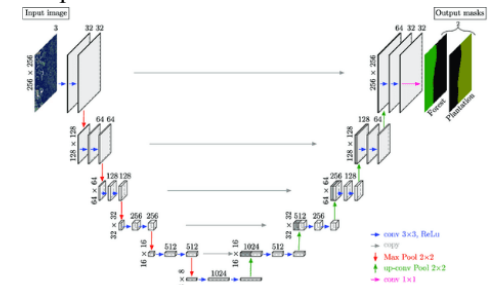


Figure 2 : Structure de l'architecture U-Net

L'architecture U-Net, telle que décrite par Ronneberger et al. (2015) [1], implémente une structure encodeur-décodeur où l'encodeur combine des blocs de double convolution (3x3) avec ReLU, normalisation de batch et max-pooling, réduisant progressivement les dimensions spatiales tout en augmentant la profondeur des caractéristiques. Le décodeur effectue l'opération inverse via des couches de déconvolution et d'up-sampling, avec des connexions résiduelles entre les différents niveaux permettant la préservation des détails spatiaux.

L'optimisation du modèle repose sur une fonction de coût hybride combinant l'entropie croisée et le coefficient de

Dice, pondéré à $\alpha = 0,7$, permettant un bon équilibre entre la classification pixel par pixel et la qualité globale de la segmentation.

$$L_{combined} = \alpha \cdot L_{dice} + (1 - \alpha) \cdot L_{ce}$$

$$L_{dice} = \frac{2|X_i \cap Y_i|}{|X_i| + |Y_i|} \text{ et } L_{ce} = \sum_{i=1,...,C} -p_i \log(\hat{p}_i)$$

Les hyperparamètres incluent une taille de batch de 8, un learning rate de 0,001, 200 époques, et l'utilisation de l'optimiseur AdamW avec une régularisation de 0,0001 pour limiter le sur-apprentissage. Le scheduler ajuste le taux d'apprentissage en cas de stagnation, réduisant ce dernier d'un facteur de 10 après 5 époques sans amélioration du coût, garantissant une convergence optimale. Le modèle comprend 130,96 millions de paramètres.

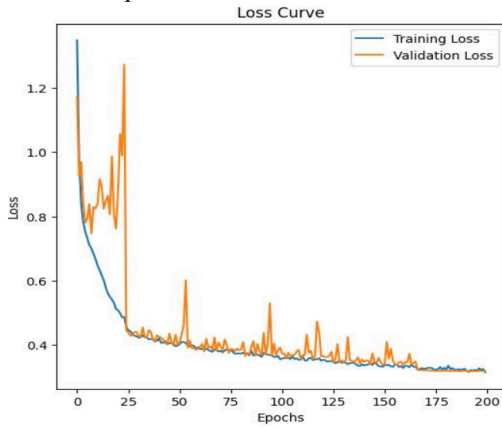


Figure 3 : Courbe d'apprentissage (Cross-entropy et Dice)

La courbe ci-dessus montre une convergence du modèle après 150 époques, on a donc un compromis entre la généralisation du modèle et sa performance, même si la courbe de validations était instable jusqu'à l'époque 25.




Figure 4 : Segmentation d'une coupe de la base de test

On observe que l'analyse des résultats révèle certaines anomalies de sur-segmentation, de sous-segmentation et d'imprécision de contours. Malgré cela, les performances générales du modèle sont satisfaisantes, avec une précision de test atteignant 98,94 % et un Dice score moyen de 0,89. Afin d'améliorer davantage ces résultats et corriger les anomalies, on peut envisager de modifier l'architecture du modèle, d'ajuster ses hyperparamètres ou de recourir à l'approche de l'apprentissage continu.

2.3. Apprentissage continu

L'apprentissage continu, ou "Continual Learning", est une approche d'entraînement des modèles d'intelligence artificielle visant à leur permettre de s'adapter en permanence à de nouvelles données sans perdre les connaissances acquises précédemment. L'objectif est de permettre aux médecins d'ajuster les résultats prédits par le modèle, puis d'utiliser ces ajustements comme nouvelles données d'entraînement afin d'améliorer les performances du modèle sur des cas similaires.

Dans la suite de cette partie, deux approches d'apprentissage continu seront présentées :

- Approche basée sur le replay
- Approche incrémentale basée sur l'Elastic weight Consolidation (EwC)

Pertinence de l'active learning

La méthode la plus naturelle consiste à prendre de manière aléatoire des segmentations incorrectes, à les annoter complètement et à réentraîner le modèle. Cependant, dans un contexte de contraintes budgétaires et d'expertise, il est nécessaire de réduire le nombre d'annotations requises. De plus, avoir simplement un grand nombre de segmentations ne garantit pas qu'elles ciblent les cas où le modèle n'a pas encore appris certaines informations. C'est pourquoi l'Active Learning (comme décrit par MONAI Active Learning [2]) est utilisé. Cette approche identifie les échantillons où le modèle est le moins confiant ou incertain dans ses prédictions. L'incertitude peut être quantifiée à l'aide de techniques telles que le Dropout Monte Carlo (où l'on active le dropout du modèle), qui génère plusieurs prédictions stochastiques pour un même échantillon, et de métriques comme l'entropie des prédictions.




Figure 5 : Carte de prédiction basée sur l'entropie

2.3.1. Approche basée sur le replay

La problématique de l'apprentissage continu réside dans l'oubli catastrophique [3]. Afin d'illustrer ce phénomène, nous avons testé deux approches sur trois bases de données représentant des modifications morphologiques des images :

1. **Naïve (ou Fine-Tuning)** : Le modèle est entraîné successivement sur chaque base sans conserver les données précédentes, ce qui conduit à une perte significative des connaissances acquises.
2. **Cumulative** : Le modèle est ré-entraîné sur la base actuelle combinée aux bases précédentes, limitant l'oubli mais augmentant considérablement les besoins en mémoire et en calcul.

Pour référence, un entraînement global utilisant simultanément toutes les bases dès le départ a également été réalisé, bien que irréaliste en apprentissage continu. Les bases incluent une première tâche classique, une seconde avec des images retournées et une troisième avec un flou gaussien. Les résultats montrent que la méthode naïve souffre fortement d'oubli catastrophique, tandis que la méthode cumulative offre de meilleures performances au prix d'un coût de calcul élevé. Ces observations soulignent la nécessité de méthodes adaptées pour gérer efficacement l'apprentissage continu.




Figure 6 : Précision en fonction des tâches Dice Score

Une approche pour résoudre la problématique de l'oubli catastrophique consiste à mélanger les anciennes données avec les nouvelles lors du réentraînement du modèle. L'objectif principal est de maintenir les connaissances acquises sur les anciennes données tout en permettant au modèle de s'adapter efficacement aux nouvelles informations. Cette méthode permet d'éviter l'oubli des paramètres précédemment appris en les réintégrant dans le processus d'entraînement, tout en assurant que le modèle soit suffisamment flexible pour évoluer avec les nouvelles données.

Lors du réentraînement, 80 slices sont utilisées avec un learning rate plus faible pour éviter de grands changements. On fait varier le ratio entre les anciennes et nouvelles données provenant des pires prédictions de la phase d'inférence. Les résultats montrent que le ratio 2/98 conduit à une chute du Dice score, indiquant une perte de performance. De plus, même avec un ratio de 98/2, où les anciennes données dominent, le modèle affiche un Dice score plus faible par rapport au modèle de base. Cela suggère qu'il existe un déséquilibre dans l'entraînement, les anciennes données n'étant pas suffisamment représentatives de l'ensemble de la base d'entraînement.




Figure 7: Évolution du Dice score pour différents ratios

Cela entraîne une incapacité du modèle à bien s'adapter aux nouvelles données tout en préservant les connaissances acquises, en même temps on ne peut pas réentraîner avec l'ensemble des données précédentes car le coût de calcul et de mémoire vont augmenter.

2.3.2. Approche incrémentale basée sur l'EWC

Toujours dans le but de réduire ce phénomène d'oubli catastrophique, nous avons choisi d'utiliser la méthode Elastic Weight Consolidation (EWC) [4]. Cette méthode identifie les poids du modèle essentiels pour les connaissances déjà acquises et limite leur modification lors de l'apprentissage de nouvelles données. Pour ce faire, une pénalisation est ajoutée à la fonction de perte, en fonction de l'importance de chaque poids. Cette importance est généralement estimée à l'aide de l'approximation de la matrice de Fisher, qui évalue l'impact de chaque paramètre sur les prédictions.

$$L_{EWC} = L_{new} + \frac{\lambda}{2} \sum_i F_i (\theta_i - \theta_i^*)^2$$

Où F_i représente l'importance du poids θ_i , et θ_i^* est la valeur optimale précédemment apprise.

La matrice de Fisher est utilisée pour estimer combien chaque poids du modèle contribue aux prédictions sur un ensemble de données. Les valeurs de cette matrice sont calculées à partir de la dérivée seconde (ou approximativement du carré des gradients) de la fonction de perte par rapport aux paramètres du modèle.

$$F_i = E_{x \sim D} \left[\left(\frac{\partial \log P(y|x, \theta)}{\partial \theta_i} \right)^2 \right]$$

Où $P(y|x, \theta)$ est la probabilité prédite par le modèle, et D est l'ensemble des données.

Dans un contexte clinique, le modèle propose une première segmentation automatique des images IRM soumises par le médecin. Ce dernier vérifie les résultats et corrige les éventuelles erreurs en ajustant les prédictions. Ces ajustements servent ensuite à réentraîner le modèle, créant une boucle adaptative. Grâce à cette approche, le modèle s'adapte aux corrections apportées par les experts médicaux tout en conservant ses connaissances initiales, essentielles à une segmentation précise. Cette méthode garantit ainsi une stabilité des performances sur les données d'origine tout en intégrant progressivement et de manière efficace les nouvelles informations corrigées, améliorant continuellement sa précision.

Pour reproduire ce fonctionnement, le protocole suivi est le suivant : un modèle initial a été entraîné sur une base de données annotée. Ce modèle est utilisé pour réaliser des inférences sur un ensemble de tests. Les prédictions obtenues sont partiellement corrigées en les comparant aux annotations parfaites (20 % de correction), simulant ainsi l'intervention d'un expert humain. Ces prédictions corrigées sont réutilisées pour une nouvelle phase d'entraînement.




Figure 8 : Pipeline de réentraînement des segmentations corrigées par l'expert

Ce processus (inférence, correction, réentraînement) est répété plusieurs fois sur la même base de test afin d'évaluer la capacité du modèle à s'adapter aux nouvelles informations.




Figure 9 : Réentraînement de la base de donnée test avec 20% de correction sur 45 itérations (avec et sans EWC)

L'entraînement est réalisé en combinant la fonction de perte de Dice et la cross-entropie. Le modèle est entraîné sur 30 époques, et cette boucle est répétée 20 fois pour évaluer son évolution. Le modèle est testé à l'aide du Dice Score.

Les résultats montrent qu'en l'absence de la méthode Elastic Weight Consolidation (EWC), la précision du modèle, mesurée par le Dice score, stagne. Cela indique que le modèle n'intègre pas correctement les corrections apportées. En revanche, avec l'intégration de la méthode EWC, les performances sur les données de test augmentent de manière significative jusqu'à 0.94 de Dice Score, démontrant une meilleure prise en compte des nouvelles corrections tout en préservant les connaissances initiales.

Ces résultats confirment l'efficacité de la méthode EWC pour gérer l'apprentissage continu dans des scénarios où les données évoluent. En limitant l'oubli des connaissances précédentes et en favorisant une intégration progressive des nouvelles informations, cette approche offre une solution adaptée aux besoins d'applications nécessitant une adaptabilité constante, comme en médecine.

3. CONCLUSION ET PERSPECTIVES

Ce rapport présente les avancées réalisées dans le cadre du projet PTI. Nous avons développé un modèle performant basé sur l'architecture U-Net, conçu pour la segmentation précise des muscles de la jambe. En utilisant une fonction de coût hybride combinant le Dice et la cross-entropie, nous avons atteint un compromis satisfaisant entre précision globale et classification pixel par pixel. Par ailleurs, nous avons implémenté et évalué plusieurs approches d'apprentissage continu. Ces méthodes visent à intégrer progressivement de nouvelles données tout en conservant les connaissances acquises, répondant ainsi aux défis posés par l'oubli catastrophique. Les résultats montrent que l'approche EWC améliore significativement les performances du modèle, confirmant son intérêt pour les scénarios évolutifs tels que les applications médicales.

En perspective, il serait intéressant d'étendre notre étude à la segmentation 3D des muscles à partir de volumes IRM complets, ce qui permettrait une meilleure exploitation des informations spatiales et une amélioration de la cohérence des prédictions.

BIBLIOGRAPHIE

[1] Ronneberger, O., Fischer, P., & Brox, T. (2015). *U-net: Convolutional networks for biomedical image segmentation*. In *Medical Image Computing and Computer-Assisted Intervention – MICCAI 2015: 18th International Conference, Munich, Germany*,

October 5-9, 2015, Proceedings, Part III (pp. 234–241). Springer International Publishing.

[2] MONAI Project. *Active Learning*. GitHub. Consulté le 20 janvier 2025. Disponible à : <https://github.com/Project-MONAI/MONAIlabel/wiki/Active-Learning>.

[3] Van de Ven, G. M., & Tolias, A. S. (2019). *Three scenarios for continual learning*. arXiv preprint arXiv:1904.07734.

[4] Kirkpatrick, J., Pascanu, R., Rabinowitz, N., Veness, J., Desjardins, G., Rusu, A. A., Milan, K., Quan, J., Ramalho, T., Grabska-Barwinska, A., Hassabis, D., Clopath, C., Kumaran, D., & Hadsell, R. (2017). *Overcoming catastrophic forgetting in neural networks*. DeepMind, London, United Kingdom, & Bioengineering Department, Imperial College London, United Kingdom. arXiv:1612.00796v2 [cs.LG] 25 Jan 2017